

# Interpolação de Lagrange e Newton: Aplicações em Inteligência Artificial

Modelagem Matemática e Otimização

27 de agosto de 2025

A aplicação dos métodos de interpolação de Lagrange e Newton no contexto da Inteligência Artificial é um tópico de grande relevância. Esta é uma área fascinante onde a matemática ganha vida em problemas práticos e computacionais. Para estudantes de Inteligência Artificial com uma base em Matemática, Cálculo, Estatística e Álgebra, a compreensão dessas ferramentas numéricas é crucial para a IA.

## 1 Interpolação Polinomial na Inteligência Artificial

A interpolação polinomial, seja por Lagrange ou Newton, é fundamental quando se precisa estimar valores em pontos desconhecidos a partir de um conjunto discreto de dados. No campo da Inteligência Artificial, isso se traduz em diversas aplicações, como:

- **Preenchimento de Dados Ausentes (Imputação):** Em datasets, é comum haver valores faltantes. A interpolação pode ser usada para estimar esses valores com base nos dados existentes, permitindo que modelos de IA sejam treinados sem lacunas.
- **Suavização de Dados e Trajetórias:** Em robótica ou sistemas de controle, a interpolação pode criar caminhos suaves para robôs ou veículos autônomos, garantindo movimentos mais naturais e eficientes.
- **Aproximação de Funções Complexas:** Algoritmos de IA podem se beneficiar da aproximação de funções não-lineares complexas por polinômios, o que pode simplificar cálculos ou permitir inferências mais rápidas.
- **Geração de Dados Sintéticos:** Em cenários onde a coleta de dados é cara ou difícil, a interpolação pode ajudar a gerar novos pontos de dados que seguem o padrão dos dados existentes.

Serão detalhados os métodos e suas aplicações.

## 2 Interpolação de Lagrange

Interpolação é o processo de encontrar um polinômio que passa exatamente por um conjunto de pontos conhecidos. O método de Lagrange constrói esse polinômio como resposta, de grau no máximo  $n$ , garantindo que ele passe por todos os pontos dados.

### 2.1 Fórmula

Dado  $n + 1$  pontos  $(x_0, y_0), (x_1, y_1), \dots, (x_n, y_n)$ , o polinômio interpolador de Lagrange com grau  $n$ , definido  $P(x)$  é dado por:

$$P(x) = \sum_{j=0}^n y_j L_j(x)$$

Onde  $L_j(x)$  são os polinômios de base de Lagrange, definidos como:

$$L_j(x) = \prod_{k=0, k \neq j}^n \frac{x - x_k}{x_j - x_k}$$

### 2.2 Exemplo com 2 pontos para método de Lagrange

Dados os pontos  $(x_0, f(x_0))$  e  $(x_1, f(x_1))$  use a fórmula de Lagrange para obter o polinômio interpolador. A interpolação por dois pontos é chamada **Interpolação Linear**:

**Solução:** Usando a fórmula de Lagrange, temos

$$P_1(x) = y_0 L_0(x) + y_1 L_1(x), \quad (1)$$

onde

$$L_0(x) = \frac{x - x_1}{x_0 - x_1}, \quad (2)$$

e

$$L_1(x) = \frac{x - x_0}{x_1 - x_0}. \quad (3)$$

Substituindo na equação (1), obtemos

$$P_1(x) = y_0 \frac{x - x_1}{x_0 - x_1} + y_1 \frac{x - x_0}{x_1 - x_0}, \quad (4)$$

ou ainda,

$$P_1(x) = \frac{y_0(x - x_1) + y_1(x - x_0)}{x_1 - x_0}. \quad (5)$$

que é exatamente a equação da reta que passa por  $(x_0, f(x_0))$  e  $(x_1, f(x_1))$ .

## 2.3 Vantagens e Desvantagens

- **Vantagens:**

- Conceitualmente simples e fácil de entender.
- A fórmula é direta e simétrica.

- **Desvantagens:**

- Adicionar um novo ponto de dados requer recalcular todo o polinômio.
- Pode ser computacionalmente intensivo para um grande número de pontos.

## 2.4 Exemplo de Aplicação em IA: Imputação de Dados em Séries Temporais

Imagine que um pesquisador está trabalhando com dados de sensores de um sistema de monitoramento ambiental para treinar um modelo de previsão de qualidade do ar. Ocasionalmente, alguns sensores falham por curtos períodos, resultando em lacunas nos dados. A interpolação de Lagrange pode ser usada para estimar esses valores ausentes, permitindo que o modelo de IA continue funcionando sem interrupções.

**Cenário:** Há leituras de temperatura a cada hora, mas algumas leituras estão faltando devido a uma falha temporária do sensor.

**Dados de Exemplo:**

- Hora ( $x$ ):  $[0, 1, 3, 4]$  (horas desde o início da coleta)
- Temperatura ( $y$ ):  $[20.0, 21.5, 23.0, 24.5]$  (graus Celsius)

Deseja-se estimar a temperatura na hora 2.

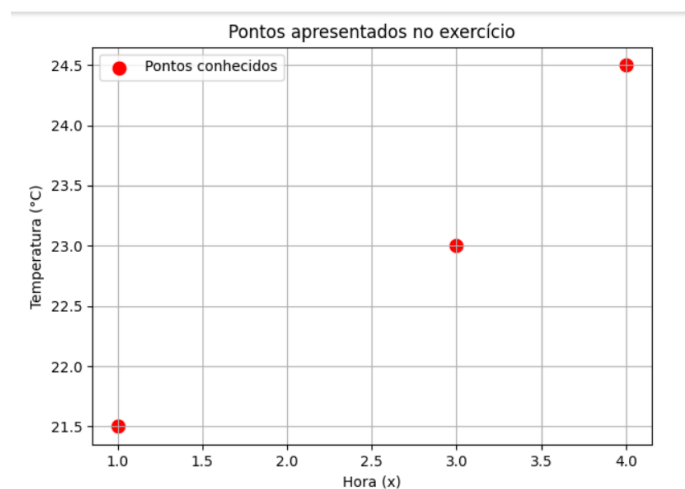


Figura 1: Leituras de temperatura a cada hora

### Resolução:

Imagine um sistema de monitoramento ambiental com leituras horárias de temperatura. Algumas leituras falharam e queremos estimar o valor faltante em  $x = 2$  (hora 2) usando interpolação de Lagrange com **três pontos** vizinhos.

#### Dados de exemplo (selecionados):

$$(x_i, y_i) \in \{(1, 21,5), (3, 23,0), (4, 24,5)\} \quad (\text{graus Celsius}).$$

#### Polinômio de Lagrange de grau 2:

$$P_2(x) = y_0L_0(x) + y_1L_1(x) + y_2L_2(x),$$

com

$$\begin{aligned} L_0(x) &= \frac{(x - x_1)(x - x_2)}{(x_0 - x_1)(x_0 - x_2)} = \frac{(x - 3)(x - 4)}{(1 - 3)(1 - 4)} = \frac{(x - 3)(x - 4)}{6}, \\ L_1(x) &= \frac{(x - x_0)(x - x_2)}{(x_1 - x_0)(x_1 - x_2)} = \frac{(x - 1)(x - 4)}{(3 - 1)(3 - 4)} = -\frac{(x - 1)(x - 4)}{2}, \\ L_2(x) &= \frac{(x - x_0)(x - x_1)}{(x_2 - x_0)(x_2 - x_1)} = \frac{(x - 1)(x - 3)}{(4 - 1)(4 - 3)} = \frac{(x - 1)(x - 3)}{3}. \end{aligned}$$

#### Estimativa em $x = 2$ :

$$\begin{aligned} L_0(2) &= \frac{(2 - 3)(2 - 4)}{6} = \frac{(-1)(-2)}{6} = \frac{1}{3}, \\ L_1(2) &= -\frac{(2 - 1)(2 - 4)}{2} = -\frac{(1)(-2)}{2} = 1, \\ L_2(2) &= \frac{(2 - 1)(2 - 3)}{3} = \frac{(1)(-1)}{3} = -\frac{1}{3}. \end{aligned}$$

$$\begin{aligned} P_2(2) &= 21,5 \cdot \frac{1}{3} + 23,0 \cdot 1 + 24,5 \cdot \left(-\frac{1}{3}\right) \\ &= \frac{21,5 - 24,5}{3} + 23,0 = -1,0 + 23,0 = \boxed{22,0^\circ\text{C}}. \end{aligned}$$

Portanto, a temperatura estimada na hora 2, usando apenas três pontos, é  $22,0^\circ\text{C}$ .




Figura 2: interpolação e estimativa para  $x = 2$

Para o resultado desenvolvido em Python acesse: [Código feito no Google Colab](#).

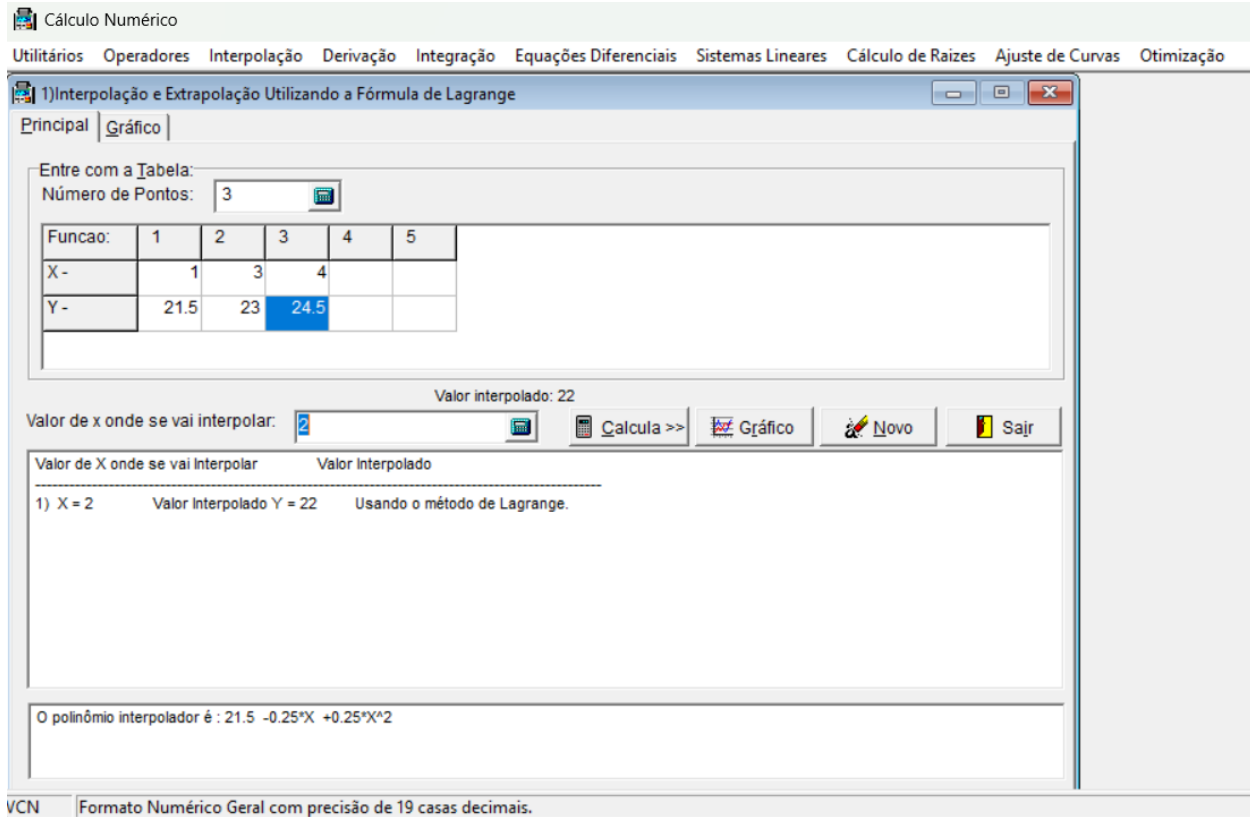


Figura 3: VCN aplicação

### 3 Interpolação de Newton (Diferenças Divididas)

O método de Newton constrói o polinômio interpolador de forma incremental, adicionando termos que dependem das "diferenças divididas". Isso é particularmente útil quando novos pontos de dados são adicionados, pois não é necessário recalcular todo o polinômio do zero.

#### 3.1 Fórmula

O polinômio interpolador de Newton  $P(x)$  é dado por:

$$P(x) = f[x_0] + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1) + \dots + f[x_0, x_1, \dots, x_n](x - x_0)(x - x_1) \dots (x - x_{n-1})$$

Onde  $f[x_i, x_{i+1}, \dots, x_j]$  são as diferenças divididas, calculadas recursivamente:

- $f[x_i] = y_i$
- $f[x_i, x_j] = \frac{f[x_j] - f[x_i]}{x_j - x_i}$
- $f[x_i, x_j, x_k] = \frac{f[x_j, x_k] - f[x_i, x_j]}{x_k - x_i}$
- E assim por diante para ordens superiores.

Para calcular as diferenças divididas sobre os pontos  $x_0, \dots, x_n$ , construímos a tabela:

**Tabela 4: Tabela de Diferenças Divididas**

$x_i$	$f[x_i]$	$f[x_i, x_j]$	$f[x_i, x_j, x_k]$	...
$x_0$	$f[x_0]$	$f[x_0, x_1] = \frac{f[x_1] - f[x_0]}{x_1 - x_0}$	$f[x_0, x_1, x_2] = \frac{f[x_1, x_2] - f[x_0, x_1]}{x_2 - x_0}$	...
$x_1$	$f[x_1]$	$f[x_1, x_2] = \frac{f[x_2] - f[x_1]}{x_2 - x_1}$	$f[x_1, x_2, x_3] = \frac{f[x_2, x_3] - f[x_1, x_2]}{x_3 - x_1}$	...
$x_2$	$f[x_2]$	$f[x_2, x_3] = \frac{f[x_3] - f[x_2]}{x_3 - x_2}$	$f[x_2, x_3, x_4] = \frac{f[x_3, x_4] - f[x_2, x_3]}{x_4 - x_2}$	...
$x_3$	$f[x_3]$	$f[x_3, x_4] = \frac{f[x_4] - f[x_3]}{x_4 - x_3}$		
$x_4$	$f[x_4]$	$\vdots$	$\vdots$	...
$\vdots$	$\vdots$	$\vdots$	$\vdots$	...
$\vdots$	$\vdots$	$\vdots$	$f[x_{n-2}, x_{n-1}, x_n] = \frac{f[x_{n-1}, x_n] - f[x_{n-2}, x_{n-1}]}{x_n - x_{n-2}}$	
$\vdots$	$\vdots$	$f[x_{n-1}, x_n] = \frac{f[x_n] - f[x_{n-1}]}{x_n - x_{n-1}}$	_____	
$x_n$	$f[x_n]$	_____	_____	

**Fonte: (BURDEN; FAURES, 2003)**

Figura 4: Tabela: Diferença divididas para o método de Newton

### 3.2 Vantagens e Desvantagens

- **Vantagens:**

- Permite adicionar novos pontos de dados sem recalcular todo o polinômio (propriedade incremental).
- Mais eficiente computacionalmente para um grande número de pontos se a ordem do polinômio for alta.

- **Desvantagens:**

- A construção da tabela de diferenças divididas pode ser um pouco mais complexa de entender inicialmente.


### 3.3 Exemplo de Aplicação em IA: Suavização de Trajetórias em Robótica

Na área da robótica, especialmente no planejamento de trajetórias de braços robóticos ou veículos autônomos, é fundamental que as transições entre os pontos de passagem (*waypoints*) sejam feitas de forma suave, evitando movimentos bruscos e ineficientes.

Uma técnica utilizada para isso é a **interpolação polinomial de Newton**, que permite gerar uma curva suave que passa por todos os *waypoints* definidos. Dessa forma, o

robô consegue executar movimentos contínuos e previsíveis, garantindo maior eficiência e segurança.

Outra vantagem importante do método de Newton é que, caso novos *waypoints* sejam adicionados (por exemplo, devido ao aparecimento de um obstáculo inesperado), a trajetória pode ser atualizada sem a necessidade de refazer todos os cálculos desde o início.



**Cenário:** Considere que um robô precisa mover seu braço através de uma sequência de posições (*waypoints*) ao longo do tempo.

**Dados de Exemplo:**

- Tempo ( $x$ ):  $[0, 1, 2, 3]$  (segundos)
- Posição Angular ( $y$ ):  $[0, 10, 15, 12]$  (graus)

Isso significa que:

- No instante  $t = 0$  s, o braço está em  $0^\circ$ ;
- No instante  $t = 1$  s, o braço deve estar em  $10^\circ$ ;

- No instante  $t = 2$  s, o braço deve estar em  $15^\circ$ ;
- No instante  $t = 3$  s, o braço deve estar em  $12^\circ$ .

A interpolação de Newton, a partir dos pontos

$$(0, 0), (1, 10), (2, 15), (3, 12),$$

gera um polinômio interpolador que descreve a trajetória angular do braço em função do tempo. Assim, o movimento resultante é suave, passando exatamente por todos os *waypoints*, e pode ser atualizado de forma eficiente caso novos pontos de passagem sejam introduzidos. Iremos obter uma função (Polinômio interpolador) que passa por este caminho.

**Cenário:** Um robô precisa mover seu braço através de uma série de posições (waypoints) no tempo.

**Resolução:** Acesse o material, observe os exercícios resolvidos e desenvolva o exercício, [Relatório UTFPR — ESPMAT III \(2013\)](#).

## 4 Comparação e Quando Usar Qual Método em IA

Característica	Interpolação de Lagrange	Interpolação de Newton
Fórmula	Soma de polinômios de base $L_j(x)$	Soma incremental de termos com diferenças divididas
Adição de Pontos	Requer recalcular todo o polinômio	Permite adicionar novos termos eficientemente
Complexidade Visual	Mais fácil de visualizar a contribuição de cada ponto	Tabela de diferenças divididas pode ser menos intuitiva
Uso em IA	<b>Imputação de dados</b> (conjunto fixo de dados), <b>aproximação de funções</b> em cenários estáticos.	<b>Suavização de trajetórias</b> (onde pontos podem ser adicionados dinamicamente), <b>modelagem adaptativa</b> (onde dados chegam sequencialmente).

## 5 Considerações Adicionais para o Estudo da Interpolação

É importante mencionar alguns pontos cruciais para a discussão com os alunos:

1. **Fenômeno de Runge:** É crucial alertar sobre o fenômeno de Runge, onde polinômios de alto grau podem oscilar violentamente entre os pontos de interpolação, especialmente com pontos igualmente espaçados. Isso pode levar a estimativas imprecisas, o que é um problema sério em aplicações de IA onde a precisão é vital.



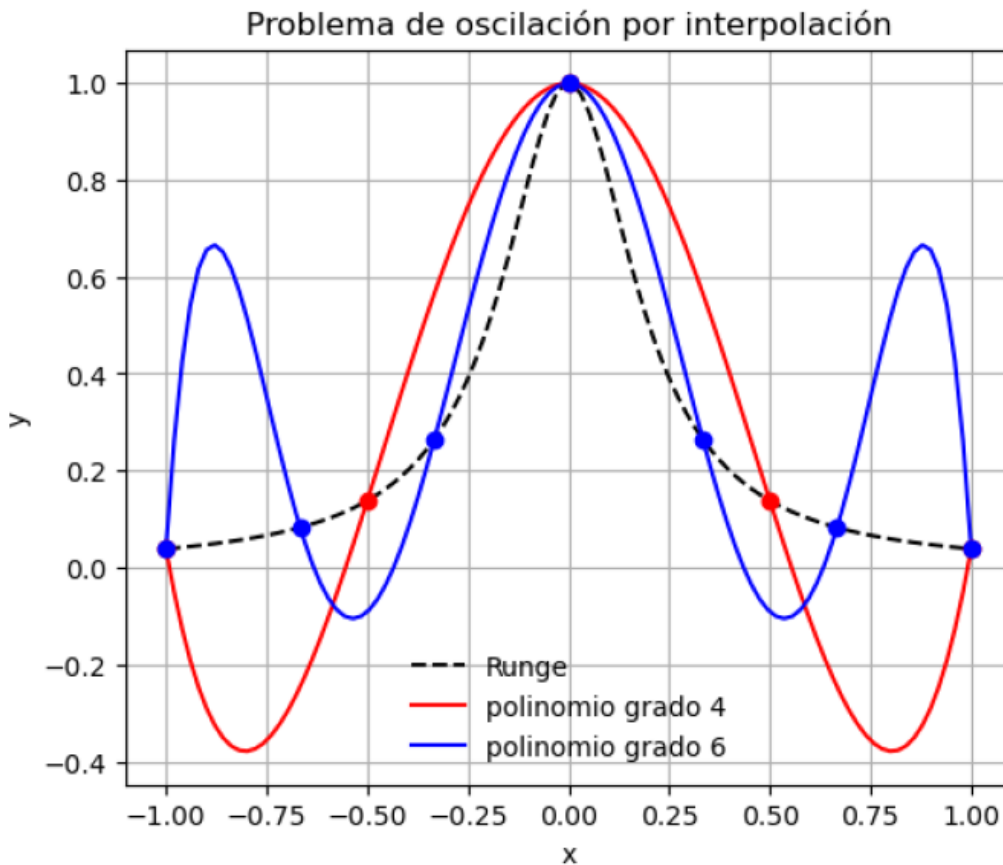


Figura 5: O Fenômeno de Runge é a oscilação indesejada que ocorre quando se usa polinômios de alto grau para interpolar pontos igualmente espaçados.

2. **Alternativas:** Para mitigar o fenômeno de Runge e obter interpolações mais estáveis, uma estratégia é **utilizar polinômios de menor grau em intervalos específicos**, em vez de um único polinômio global de alto grau. Isso reduz as oscilações e torna a aproximação mais robusta. Outra opção bastante utilizada na prática é o uso de **splines cúbicos**, que também oferecem suavidade. Para leitura complementar, consulte o relatório completo disponível em: [Relatório UTFPR — ESPMAT III \(2013\)](#).
3. **Extrapolação:** É fundamental lembrar que a interpolação é para estimar valores *dentro* do intervalo dos dados conhecidos. Usar esses polinômios para *extrapolar* (estimar valores *fora* do intervalo) é geralmente arriscado e pode levar a resultados muito imprecisos, pois o comportamento do polinômio fora dos pontos conhecidos não é garantido.